脑出血智能诊疗数据集建设：

会议讨论目标与议题

主要议题分为五块

1. 初期阶段做脑出血病种聚焦
2. 脑出血从发病到复诊的真实临床闭环细节科普
3. 脑出血闭环AI赋能
4. 初期阶段数据集收集
5. 医院侧协作支持

最终目标：

输入病例描述+影像+病史，然后输出完整治疗路径、手术方案、药物方案

初期目标：

脑出血病例放射报告生成。 原因：结构化的MLLM放射报告生成最近的NC子刊（2025）上有相关范式可以借鉴， 包含新定义的相关评测指标。

预期交付结果：（初期）

和医生相似的放射报告生成，相近的描述和正确率

进阶目标：

脑出血初诊放射报告生成+输出急性治疗/手术路径

---

1. 脑出血病种范围确认

关键临床问题咨询

- 初期阶段是否适合先聚焦最核心的 1 到 2 类?
- 对于建议纳入的病种，是否存在明显的数据获取难度与病例一致性问题（不同人对相同的内容的描述是否相同）？

候选病种

病种	临床重要性	数据可得性	标注一致性	第一阶段是否建议纳入	医生备注

病种	临床重要性	数据可得性	标注一致性	第一阶段是否建议纳入	医生备注
自发性脑内出血（ICH）					
脑室出血（IVH）					
蛛网膜下腔出血（SAH）					
硬膜下血肿（SDH）					
硬膜外血肿（EDH）					
创伤性颅内出血（TICH）					
出血性转化（HT）					

讨论记录

- 第一阶段优先考虑:
- 第一阶段暂不考虑:

---

2. 脑出血闭环流程确认

发病/症状 -> 急诊分诊 -> 头颅CT/首诊判断 -> 住院/ICU/手术决策 -> 治疗与监测 -> 复查影像 -> 复诊/长期结局

需医生评估的关键问题

A. 发病及到院前评估

- 一般而言，从入院触发，（只是知道症状）是直接进入正常急诊后转卒中急诊，还是经过急诊导诊直接进入卒中急诊？（这里可能能够利用模型去做一个卒中导诊，已经有人这么做， 但不在导诊）
- 到院前最关键的病史信息有哪些？

B. 急诊及初诊流程

- 首诊时标准流程细节？
- 第一个关键影像是否通常是平扫 CT？（网上共识）什么时候会加 CTA/MRI？
- 在首诊阶段，哪些CT特征是关键的判断项？（做急诊的ai辅助诊疗， 可用于构建合适结构的提示词微调方法，等价于引入医学先验）

C. 住院及治疗管理

- 哪些 CT 特征提示保守治疗/ICU 监测/手术干预？（做急诊的ai辅助诊疗， 可用于构建合适结构的提示词微调方法，等价于引入医学先验，提示模型关注相关部分细节）
- 临床上最担心哪些并发症和恶化风险？（医学先验）

D. 复查与临床结局评估

- 复查影像的典型时间点是什么？
- 复查CT上最关键的变化指标有哪些？ （如果后续做复诊的ai辅助诊疗， 可用于构建合适结构的提示词微调方法，等价于引入医学先验 ）

讨论记录

- AI医疗项目初步，更希望覆盖的流程段：首诊CT报告生成（不含诊疗报告）+（诊疗建议）？ 复查CT？ 是否现在有脑部的诊疗报告生成的大模型工作？

---

3. 临床流程中 AI 优先应用环节

关键临床问题咨询

- 哪些环节易出现误判或漏诊？
- 哪些环节依赖资深经验或繁琐耗时？
- 哪些环节最影响临床处理及时性？

现存 AI 功能任务模块

举例： 急诊CT分析：CT扫描完成后，AI自动识别出血类型、血肿大小、脑室受累等关键指标。（放射科报告+诊断） 提示临床处理优先级：AI标记“需要手术或ICU立即处理”，通知医生优先处理。 --可生成的结构化tag

- Deep learning algorithms for detection of critical findings in head CT scans: a retrospective study （柳叶刀2018）

A. 放射影像理解与报告生成模块 （初期工作）

子任务	更像独立任务，还是报告生成链上的一部分	临床价值	数据可得性	标签一致性	第一阶段优先级	医生备注
出血检测						
出血分型						
出血定位						
严重程度结构化评估（体积/中线移位/脑积水等）						
结构化报告生成						

B. 临床工作流辅助模块 （进阶工作）

子任务	主要服务哪一环	临床价值	数据可得性	标签一致性	第一阶段优先级	医生备注
高危病例排序 / 工作列表优先级调整						
ICU / 手术风险提示						

子任务	主要服务哪一环	临床价值	数据可得性	标签一致性	第一阶段优先级	医生备注
临床辅助摘要						

C. 随访及病程演化分析模块 （进阶工作）

子任务	是否适合第一阶段	临床价值	数据可得性	标签一致性	第一阶段优先级	医生备注
复查变化对比						
血肿扩张风险预测						
预后 / 结局风险评估						

AI 功能临床价值评估征询

- 在三类任务中，哪类 AI 功能最有临床价值、最需要优先部署？
- 根据实际工作流程，目前医院 AI 是否已经存在辅助部署？
- 医院更希望第一阶段AI 优先提供哪些支持？

讨论记录

- 第一阶段最适合作为主任务块的是：
- 第一阶段更适合作为子输出的是：
- 第一阶段暂时不适合做的是：
- 目前医院 AI 已经能做到哪些功能：

---

4. 第一阶段数据集核心内容

A. 影像数据收集

关键问题：

- 共多少病人的病例可拿？ 一位病人能在初诊+复诊提供多少图像？
- 是否存在整个病人的病程链路信息收集机制？
- 相关信息移交以什么形式？ 初期目标下，单纯CT+检验报告预期有多少量？
- 复查 CT 是否能关联到同一病程？
- 具体的信息格式如何交付？ 能否提供初步的病例信息整理支持？ （预期较为繁琐，需要医院侧人力投入）

B. 文本与病程数据

关键临床问题咨询：

- 首诊病历
- 影像报告
- 手术记录

- 复诊记录
- 出院小结
- 最终诊断
- 关键时间戳

这些内容中，哪些是稳定可拿的，哪一些是存在但不稳定获取的？

C. 结构化标签与量表定义

希望能和医生一起判断：为了构建“脑出血多模态微调和评测数据集”，结构化字段是否至少应该分成下面 4 层。（合适的结构化字段设计，预期有助于模型的在初步任务，影像分析报告，的性能表现）

1. 病种识别层 （初期工作）

字段	是否必须	能否稳定获取	是否需要人工标注	医生备注
出血大类主标签（ICH/IVH/SAH/SDH/EDH/混合型）				
病因分类（自发性/创伤性/动脉瘤相关/AVM相关/其他）				
出血部位				
是否多部位出血				
是否破入脑室				
是否创伤相关				
是否提示血管异常病因				

2. 严重程度层 （初期工作）

字段	是否必须	能否稳定获取	是否需要人工标注	医生备注
出血量 / 体积				
是否中线移位				
是否脑积水				
是否血肿扩张				
GCS				
NIHSS				
ICH score				

3. 治疗过程层 （进阶工作可能用到）

字段	是否必须	能否稳定获取	是否需要人工标注	医生备注

字段	是否必须	能否稳定获取	是否需要人工标注	医生备注
是否手术				
手术方式 / 介入方式				
ICU / 病房去向				
关键治疗措施				
是否发生重要并发症				
复查影像时间点				
复查变化结论				

4. 结局层 （进阶工作可能用到）

字段	是否必须	能否稳定获取	是否需要人工标注	医生备注
出院结局				
是否住院死亡				
出院时功能状态				
90 天 mRS 或其他长期结局				
是否再次入院 / 再出血				

5. 需医生评估的关键数据字段 （进阶工作可能用到）

- 上面这 4 层字段，是否能够较好覆盖一个脑出血患者的关键信息？
- 有没有哪些关键临床信息没有被覆盖，但医生认为必须加入？
- 有没有哪些字段只适用于部分脑出血病种，而不适合做全局统一字段？
- 初期任务中，是否存在字段重要， 但无法先从现有病历/放射学报告稳定抽取？

---

5. 医生参与协作机制

5.1 预期医生协助的内容

1. 帮我们定义第一阶段病种范围和纳入标准，协助高质量医学先验的结构化提示词注入制定。
2. 提供大规模多模态图文对齐数据。
3. 抽样复核数据质量和结构化抽取结果。
4. 对gt报告与predict报告做偏好打分或可用性打分。
5. 对失败案例做专家复盘，提供改进方向，形成闭环。

5.2 具体支持内容（初步预期）

5.2.1 诊断报告结构化效果核对

为评估并校正结构化诊断报告时的准确性，按随机方式从处理结果中抽取5%的样本进行人工核对。

5.2.2 大规模多模态图文对齐数据集的标准化采集与采样构建

可借鉴的规模：3D-BrainCT 数据集 train: 7,751名患者，15247个CT（多次扫描）test: 1,938名患者测试，3638个CT total : 9689名患者，共18885 。 + 对应人工放射报告

5.2.3 图灵测试标注需求

为评估由模型生成的影像报告在临床可辨识性与实用性方面的表现，现存的可借鉴的图灵测试组织方式如下：

-----测试样本 132份报告，同一病例两份报告：一份人类专家，一份为模型生成，11名医师参加评审。

实验分两阶段进行：

第一阶段，评审者仅查看两份报告的文字内容，回答以下问题：

Q1：哪一份是 AI 写的？（可选择“第一份”/“第二份”/“都不是/都不是”）

Q2：你对自己判断的信心有多大？（按李克特量表 1–5 评分）

Q3：影响你判断的主要因素是什么？（如逻辑连贯性、细节具体程度、行文语气、写作质量等，评审者可多选）

第二阶段，系统展示对应病例的CT 影像与两份报告，评审者在复核影像后可修改或确认第一阶段的判断（再次回答 Q1–Q3，并更新信心评分）。

5.2.4 报告评测打分需求

组织临床专家对抽样的GT报告与模型生成的predict报告分别独立评分（每组各100份）。

为了将专家的主观临床经验转化为可计算的客观数据，我们将采用学术界通用的5分制李克特量表。参与评测的专家需针对5个独立维度（诊断准确性、语言质量、放射学细节、信息密度比例、健全性等效）逐一进行标准化赋分，并给出明确锚点与判定示例以确保评分一致性与可复现性：

1分（极差/强烈不认同）：报告存在致命缺陷（如重大病灶漏诊、定性严重错误），完全误导临床决策，毫无可用性。

2分（较差/不认同）：报告存在明显瑕疵或关键信息缺失，需主治医师进行大幅度重写方可使用。

3分（一般/中立）：报告基本合格，无致命诊断错误，但行文或细节描述需中等程度的修改，勉强达到临床基线要求。

4分（较好/认同）：报告准确且描述较为完整，仅需微调个别措辞或补充少量细节，高度符合临床预期。

5分（极好/强烈认同）：报告完美契合人类高级专家的诊断水平与行文习惯，无需任何修改即可作为最终报告直接发布。

协作方式与流程说明

协作方式	是否能够协助	负责人	频率	医生备注

协作方式	是否能够协助	负责人	频率	医生备注
定义第一阶段病种范围和纳入标准，协助高质量医学先验的结构化提示词注入制定				
提供大规模图文对齐数据				
抽样复核数据质量和结构化抽取结果				
图灵测试标注需求				
报告评测打分需求				
失败案例复盘				

FORTENC + 大模型医学评测（2025NC 评测标准） 部分结构化拆解示例

FORTE 是一种面向放射学报告生成的结构化语义评测方法。 （注意， 放射学报告生成） 先从真实报告和模型生成报告中分别抽取关键信息，再按固定维度进行对齐比较。 这里的真实报告与模型输出，都会先被拆解为结构化语义项，主要包括四类：

- 程度：大小、范围、轻重程度
- 部位：解剖位置
- 特征：病理或影像学表现
- 印象：综合诊断结论

示例

真实报告

- 右侧基底节区脑内出血，约 28 mL
- 血肿破入右侧脑室
- 轻度中线左移
- 考虑高血压性脑内出血

模型输出

- 右侧基底节区脑内出血
- 出血量中等，伴脑室受累
- 可见轻度中线偏移
- 考虑高血压相关脑内出血

结构化对比

维度	真实报告	模型输出
程度	28 mL；轻度	中等；轻度
部位	右侧基底节区；右侧脑室	右侧基底节区；脑室
特征	脑内出血；破入脑室；中线左移	脑内出血；脑室受累；中线偏移

维度	真实报告	模型输出
印象	高血压性脑内出血	高血压相关脑内出血