数据集补充

刘珂华 | Modified Today

HuatuoGPT-Vision

仓库三大核心：

1. PubMedVision 数据集
2. HuatuoGPT-Vision 模型
3. 训练 + 评测代码

PubMedVision数据集构建：

研究团队从医学论文中提取：

- 医学论文中的 **figure及其对应caption**
- 图像上下文信息

提取出**图文对。**

图像筛选：

第一轮：研究团队训练了一个 **CLIP-based 图像分类器**来过滤，这个分类器使用使用**由人工专家手动标注的 1000 张图片**用来作为**高质量训练数据**：

保留：X-ray、CT、MRI、病理图、超声、医学示意图

去除：charts（例如柱状图、折线图、统计图）、diagrams（一般性流程图或结构图）、non-medical figures（非医学相关图片）

第二轮：从最初抓取的1100万 PubMed figure中随机抽取10000图像，使用 GPT-4V 自动标注的10000张图像样本作为验证医学图像分类器的数据集。

使用GPT-4V 生成 VQA / instruction 数据：

GPT-4V理解图像和caption内容，自动生成医学问答，同时生成医学图像描述（medical caption）。最终每条数据都会整理成统一的数据结构，包括图像、问题、答案和医学描述，从而构建大规模医学VQA训练数据。

例如：原始数据包括：image: CT image，caption

GPT-4Vquestion生成：question，answer，medical_caption

最终数据结构：{image,question,answer, medical_caption}

通过上述步骤，构建出PubMedVision医学多模态数据集（ 6M 医学图文对， 数百万 VQA instruction）

目前HuatuoGPT-Vision提供两个不同规模的模型。

模型	Backbone
HuatuoGPT-Vision-7B	Qwen2-7B
HuatuoGPT-Vision-34B	Yi-1.5-34B

本质结构为：Vision Encoder+LLM→Multimodal LLM

目前训练框架使用：Qwen2.5-VL

训练流程：

一、视觉模型初始化（LLM+Vision Encoder→Vision Language Model）

二、Vision Alignment（视觉对齐，监督学习）

三、Vision Instruction Tuning（视觉指令微调，image + question → answer，数据集：PubmedVision）

模型评测：

Benchmark	图像类型	任务类型	数据规模	评测能力
VQA-RAD	CT / X-ray / MRI	放射影像问答	3515 QA	基础医学影像理解
SLAKE	CT / MRI / X-ray	多语言医学VQA	14k QA	多语言医学理解
PathVQA	病理显微图	病理图像问答	32k QA	细粒度组织识别

PMC-VQA	医学论文图	科学图像问答	290k QA	论文图表理解
OmniMedVQA	多模态医学图	综合医学VQA	多来源	跨领域能力
MMMU-Medical	医学图像	多模态推理	exam-style	医学推理能力

Performance of Medical Multimodal

	VQA-RAD	SLAKE	PathVQA	PMC-VQA
LLaVA-Med-7B	51.4	48.6	56.8	24.7
LLaVA-v1.6-34B	58.6	67.3	59.1	44.4
HuatuoGPT-Vision-7B	63.7	76.2	57.9	54.3
HuatuoGPT-Vision-34B	**68.1**	**76.9**	**63.5**	**58.2**

	OmniMedVQA	MMMU Health & Medicine (Test Set)
LLaVA-Med-7B	44.5	36.9
LLaVA-v1.6-34B	61.4	48.8
HuatuoGPT-Vision-7B	74.0	50.6
HuatuoGPT-Vision-34B	**76.9**	**54.4**

结果表明 HuatuoGPT-Vision 在多个医学 benchmark 上取得了更好的性能。

Towards a holistic framework for multimodal LLM in 3D brain CT radiology report generation

提出问题：

1. 缺乏3D医学影像数据集
2. LLaVA-Med等模型只能处理：单张图或少量图，但CT是体数据，模型必须能够理解：空间位置、病灶大小、病灶程度。
3. 传统评测：BLEU、ROUGE、METEOR、CIDEr等都是自然语言生成评测标准，但医学报告不只看重语言质量，更为重要的是诊断信息密度

文章贡献：

1. 构建大规模 3D-BrainCT 专用数据集
2. 提出 BrainGPT 模型与 CVIT 训练方法
3. 提出FORTE 评测体系

3D Brain CT dataset数据集构建：

规模：18885 image-report pairs （3D CT volume+Radiology report）

数据均为真实临床数据

放射学报告结构一般为：Observation list　Conclusion，即 Finding1，Finding2，Finding3，Conclusion

数据特征：

数据包含四类医学信息：

1. Degree（程度）：tiny、mild、extensive、severe等
2. Landmark（解剖位置）：internal capsule、thalamus、corona radiata、ventricle等
3. Feature（病理特征）：morrhage、calcification、low density、infarction等
4. Impression（诊断）:lacunar infarction、angiopathic leukoencephalopathy等

这四类后来成为FORTE评测体系

BrainGPT模型构建：

BrainGPT 是一个基于 Otter 架构构建的多模态大语言模型（MLLM），主要用于将 3D 脑部 CT 影像自动生成放射学报告。

在整体结构上，BrainGPT 由三个核心部分组成：视觉编码模块、跨模态连接模块以及语言生成模块。

模型使用 CLIP ViT-L/14 作为视觉编码器。该模块负责对输入的 CT 图像进行特征提取，将原始医学影像转换为一系列高维视觉特征向量，从而捕获影像中的关键医学信息。

随后将视觉特征向量送入 Perceiver Resampler 模块，对视觉特征进行压缩与重采样，将大量视觉 token 转换为少量、更紧凑的视觉表示，从而保留关键影像信息的同时降低计算复杂度。

模型通过 Cross-Attention将视觉特征与语言模型进行连接。

BrainGPT 使用 LLaMA-7B 作为语言模型。

模型训练（CVIT）：

作者设计了四种 instruction tuning：

1. Plain Instruction（看图 → 写报告）
2. Example Instruction（在1基础上加入少许示例样本）
3. Template Instruction（在前者基础上加入了医学报告模板，模型被要求按照此结构输出）
4. Keyword Instruction（模型被要求围绕degree、landmark、feature、impression进行分析，形成诊断思维流程）

最终得到四个模型：BrainGPT-plain、BrainGPT-example、BrainGPT-template、BrainGPT-keyword

最终结果：**BrainGPT-keyword（最好）**>BrainGPT-template> BrainGPT-example> BrainGPT-plain（最差）

医学报告生成不是普通描述任务，医生诊断的思维为：degree→landmark→lfeature→limpression，因此keyword instruction 直接将此医学诊断结构强制给模型，使其生成的报告更接近真实医生

传统评测不适合医学报告（长文本、大量否定表达、内容顺序不固定），针对此，论文提出对数据进行两阶段预处理：

1、针对报告顺序不同，BLEU会判定错误：把报告逐句拆分，再逐句对齐评估。

2、针对医学报告存在大量否定（模型易发生Interpretation spree）：评测时去掉no、not、without，仅对阳性结果进行评估。

核心评测体系（FORTE,Feature-Oriented Radiology Task Evaluation），实质上为字段性评测：

对医学信息密度进行评测，而不是语言相似度。

首先，作者建立了医学关键词词典，且支持同义词

四类关键词：Degree（程度）、Landmark（解剖位置）、Feature（病理特征）、Impression（诊断）

对于每一类关键词，我们计算precision（精确率，Precision=TP/FP+TP）、recall（召回率，Recall=TP/FN+TP）、F1 Score（F1=2*Precision+Recall/Precision+Recall，越接近1越好）

类别	F1
Feature	0.693
Landmark	0.706
Degree	0.661
Impression	0.779

Average F1 = 0.71

评测体系验证：

作者作了三种验证：

1、与传统指标对比：传统指标间：r>0.7，但FORTE r<0.5，证明FORTE评测的是不同维度的信息。即传统指标之间高度相关，因为它们都在测文本相似度，FORTE评估的是结构信息理解能力。

2、LLM-as-a-judge：作者使用DocLens（专用于医学文本评估的 LLM 评审框架）对medical claim accuracy进行评估，发现DocLens 与 FORTE：r = 0.78，说明：FORTE能反映真实医学质量。

3、医生人工评估（50个报告）：对Diagnostic accuracy（诊断准确性）、Linguistic quality（语言质量）、Radiologic detail（影像细节）、Information density（信息密度）、Soundness equivalence（医学等价性）五个指标进行评估，FORTE 与人工评分ICC ≈ 0.62

证明：FORTE 是可靠的医学评测指标。

外部测试：

验证模型的泛化能力，使用了CQ500数据集中共133个CT。

识别分类任务，即识别三种脑部异常：mass effect（占位效应）、hemorrhage（脑出血）、midline shift（中线移位）

评测指标：Accuracy（准确率）

mass effect ≈ 0.71

hemorrhage ≈ 0.59

midline shift ≈ 0.86，因此，证明模型有一定泛化能力。

图灵测试：

实验邀请 11名具有临床经验的医生参与评测，74% 的 AI 报告被医生认为是人类医生撰写的，证明该模型生成报告在语言表达、医学术语使用和叙述结构上，已经高度接近真实医生报告。